

Listas de contenidos disponibles en [ScienceDirect](https://www.sciencedirect.com)

Informática en Biología y Medicina

Página principal de la revista: www.elsevier.com/locate/combiomed

Generación condicional de ECG basada en difusión con modelos estructurados de espacio de estados

Juan Miguel López Alcaraz, Nils Strodthoff *

La Universidad de Oldenburg, 26129 Oldenburg, Alemania

ARTICLE INFO

Palabras clave:

Cardiología
Electrocardiografía
Procesamiento de señales
Datos sintéticos Modelos
de difusión Series
temporales

ABSTRACT

Generar datos sintéticos es una solución prometedora para abordar las preocupaciones de privacidad que surgen al distribuir datos de salud sensibles. En los últimos años, los modelos de difusión se han convertido en el nuevo estándar para generar diversos tipos de datos, mientras que los modelos estructurados en espacios de estados han surgido como un enfoque potente para capturar dependencias a largo plazo en series temporales. Nuestra solución propuesta, SSSD-ECG, combina estas dos tecnologías para generar electrocardiogramas sintéticos de 12 derivaciones basados en más de 70 declaraciones de ECG. Como faltan líneas de base fiables, también proponemos variantes condicionales de dos modelos generativos incondicionales de última generación. Realizamos una evaluación exhaustiva de la calidad de las muestras generadas evaluando clasificadores preentrenados a partir de los datos generados y midiendo el rendimiento de un clasificador entrenado únicamente con datos sintéticos. SSSD-ECG superó a sus competidores basados en GAN. Nuestro enfoque fue validado además mediante experimentos que incluyeron interpolación condicional de clases y una prueba de Turing clínica, que demostró la alta calidad de las muestras SSSD-ECG en una amplia gama de condiciones.

1. Introducción

Sin duda, la enorme cantidad de datos generados en todo el mundo ha sido un catalizador importante para avances significativos en aprendizaje automático en una variedad de tipos de datos y aplicaciones. Sin embargo, solicitar y compartir datos puede presentar desafíos, incluso entre diferentes departamentos dentro de la misma organización, debido a preocupaciones de privacidad. Esto es especialmente cierto en campos sensibles a la privacidad como la sanidad. Se han realizado esfuerzos significativos para mejorar la seguridad y privacidad de los datos sanitarios mediante la implementación de regulaciones como el RGPD o HIPAA [1,2], medidas de cumplimiento [3–5], así como el desarrollo de soluciones técnicas como la tecnología blockchain o el aprendizaje federado [6,7]. Sin embargo, incluso soluciones técnicas como el aprendizaje federado por sí solas no garantizan una protección completa de la privacidad, ya que los modelos entrenados pueden reconstruirse para revelar muestras de entrenamiento mediante ataques de inversión de modelos [8]. Por lo tanto, debe emplearse una combinación de diferentes técnicas para mejorar la privacidad.

La capacidad de crear réplicas digitales de datos en bruto, conocida como digital

Twins es una solución viable que preserva las propiedades estadísticas de los datos originales mientras elimina información personal del paciente. Las técnicas de aumento de datos, como los métodos estadísticos, proporcionan una protección limitada de la privacidad al disfrazar los datos originales. Por ello, el uso de modelos generativos de aprendizaje automático se ha vuelto cada vez más popular. Sin embargo, es importante asegurarse de que los datos recreados sean precisos, de lo contrario pueden estar sesgados [9] y afectar negativamente a las tareas posteriores

y la toma de decisiones, incluida la interpretabilidad [10]. Esto pone de manifiesto la necesidad de modelos generativos que puedan producir muestras de alta calidad basadas en diferentes características del paciente, así como el desarrollo de criterios objetivos de referencia para evaluar la calidad de las muestras generadas.

Recientemente, los modelos de difusión han mostrado resultados notables para la síntesis de datos, superando a otros modelos como las redes generativas adversariales (GANs) o los modelos autorregresivos. Se ha demostrado que estos modelos presentan sesgos hacia clases de alta densidad [11], así como distribuciones de conjuntos de datos de baja fidelidad [12,13], y se sabe que sufren de inestabilidades en el entrenamiento [14]. Además, los modelos de difusión han mostrado mejoras en diversas tareas posteriores [15] y han ayudado en la identificación de nuevas patologías [16].

En este estudio, nuestro enfoque está en generar datos de electrocardiogramas sintéticos. El ECG es un procedimiento médico comúnmente utilizado debido a su naturaleza no invasiva, tecnología sencilla y fiable, y alto valor diagnóstico. Es una herramienta esencial para la evaluación inicial del estado cardíaco general del paciente. Esta importancia se pone aún más de manifiesto con los avances recientes en el análisis ECG basado en IA, como se discute en [17]. Sin embargo, muchos estudios de alto impacto sobre el análisis de ECG se han realizado utilizando conjuntos de datos privados, lo que supone un problema significativo en términos de reproducibilidad y dificulta el progreso en la comunidad investigadora en su conjunto. Para permitir el intercambio de estos conjuntos de datos, se utilizan gemelos digitales de alta calidad de conjuntos de datos privados, que contienen datos de pacientes altamente sensibles y

están sujetos a estrictos requisitos de privacidad, deben ser generados. Demostramos este proceso creando y evaluando copias sintéticas del conjunto de datos público PTB-XL [18–20], que es un conjunto de datos popular de ECG.

Las principales contribuciones de este trabajo son las siguientes: (1) Proponemos un modelo de difusión para generar ECGs cortos (10 s) de 12 derivaciones. Este modelo utiliza un modelo de espacio de estados estructurado como su componente interno. (2) Introducimos variantes condicionales de dos modelos generativos incondicionales de última generación para datos de ECG. (3) Generamos versiones sintéticas de PTB-XL, un gran conjunto de datos de ECG disponible públicamente, y evaluamos la calidad de las muestras generadas entrenando y probando clasificadores con estos conjuntos de datos. (4) Demostramos que nuestro modelo ha internalizado el conocimiento del dominio de varias maneras: (a) comparando muestras generadas mediante una agregación a nivel de latido entre subgrupos de muestras con patologías comunes, (b) interpolando de forma significativa entre diferentes conjuntos de condiciones, y (c) realizando una evaluación experta en forma de una prueba de Turing clínica que confirma la alta calidad de las muestras generadas.

2. Materiales y métodos

2.1. Conjunto de datos y tarea aguas abajo

El enfoque de este estudio está en ECGs cortos de 12 derivaciones que duran 10 segundos. Estos ECG se obtienen de seis derivaciones de las extremidades y seis derivaciones precordiales, que es el método más utilizado en la práctica clínica. Los ECG se muestrearon a una frecuencia de 100 Hz, ya que investigaciones previas han demostrado que aumentar la frecuencia de muestreo a 500 Hz no mejora significativamente la capacidad para clasificar los ECG [21].

Conjunto de datos PTB-XL

Nuestros experimentos se basan en el conjunto de datos PTB-XL [18–20], que es una colección pública de datos clínicos de ECG de 12 derivaciones que comprende 21.837 registros de 18.885 pacientes. Para entrenar de alta calidad

Modelo generativo, es importante contar con un conjunto de datos de tamaño suficiente. Para modelos generativos condicionales de clase, que requieren anotaciones por muestra para todas las muestras del conjunto de datos, similares a los discríms supervisados-

Entrenamiento inactivo, PTB-XL es una buena opción ya que proporciona anotaciones para cada muestra en términos de 71 sentencias ECG en un conjunto de múltiples etiquetas. Estos abarcan 44 diagnósticos (organizados en 24 subclases y 5 superclases que comprenden normal, alteración de conducción, infarto de miocardio, hipertrofia, cambios ST/T), 19 relacionados con la forma (5 de los cuales también contaban como declaraciones diagnósticas), como complejo QRS anormal, y 12 enunciados relacionados con el ritmo, como fibrilación auricular. Cabe destacar que este conjunto de datos representa un avance significativo en términos de complejidad, ya que incluye un amplio conjunto de 71 sentencias ECG, que pueden utilizarse en un entorno multi-etiqueta. La mayoría de los enfoques literarios se han centrado típicamente en una sola condición, como muestras sanas, o en generar muestras basadas en conjuntos muy limitados de etiquetas de clase. Para más información sobre el conjunto de datos, consulte el [Apéndice A](#) y el descriptor del conjunto de datos [18].

Tarea posterior

Como tarea posterior, estamos examinando el problema de predecir las declaraciones del ECG al nivel más detallado, lo que implica clasificarlas en múltiples etiquetas. Esta tarea es un punto de referencia bien investigado en el conjunto de datos PTB-XL, y seguimos la metodología establecida descrita en trabajos previos [22]. En particular, utilizamos los pliegues estratificados propuestos para el entrenamiento de modelos, donde los primeros 8 pliegues se usan para entrenar, el noveno doble sirve como conjunto de validación y el décimo como conjunto de prueba. Nuestra métrica de evaluación para esta tarea es el área macropromediada bajo la curva de operación del receptor (macro AUROC) en las 71 etiquetas del conjunto de pruebas PTB-XL. Como arquitectura de modelo, utilizamos un modelo XResNet1d50, que es una adaptación unidimensional de un modelo moderno de ResNet [23], como se propone en [22]. Seguimos de cerca la metodología de entrenamiento y evaluación descrita en [22], con una dicción binaria

la pérdida de cruz como objetivo de entrenamiento, lo cual es apropiado para un problema de clasificación multi-etiqueta. Entrenamos el modelo en cultivos aleatorios de 2,5 s de longitud y, durante el tiempo de prueba, promediamos siete predicciones superpuestas de la misma muestra para obtener la predicción final para la muestra. Para evitar el sobreajuste, independientemente de si entrenamos con datos reales o sintéticos, siempre realizamos la selección del modelo basada en una puntuación de validación real/sintética correspondiente (macro AUC). Para más información sobre el clasificador y la formación aguas abajo, consulte el [Apéndice B](#).

2.2. Modelos de

difusión de fondo

Modelos de difusión [24], que son un tipo de modelo generativo, han demostrado un rendimiento de vanguardia en una variedad de modalidades de datos, incluyendo datos de audio [25,26], datos de imagen [12,27–29] y datos de video [30]. Los modelos de difusión consisten en dos procesos: el proceso hacia adelante y el proceso hacia atrás. Durante el proceso hacia adelante, el ruido se introduce de forma incremental de manera markoviana. En cambio, durante el proceso de retroceso, el modelo elimina gradualmente el ruido. El proceso directo se parametriza como

$$q(x_1, \dots, x_T | x_0) = \prod_{t=1}^T q(x_t | x_{t-1}), \quad (1)$$

donde $q(x_t | x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t} x_{t-1}, \beta_t)$, β_t son variaciones de proceso adelante (fijas o aprendibles), que ajustan el nivel de ruido y T es el número de pasos de difusión. Equivalentemente, π puede expresarse en forma cerrada como $\pi(x_t) = \mathcal{N}(x_t; \sqrt{\alpha_t} x_0 + (1 - \alpha_t) \epsilon, \sigma_t^2)$ para $\epsilon \sim \mathcal{N}(0, I)$, donde $\alpha_t = \prod_{s=1}^t (1 - \beta_s)$. E el proceso hacia atrás se parametriza como en la Ecuación. (2), donde $x_T \sim \mathcal{N}(0, I)$.

$$p_\theta(x_0, \dots, x_{t-1} | x_t) = \prod_{t=1}^T p_\theta(x_{t-1} | x_t) \quad (2)$$

Usando una parametrización particular de $p_\theta(x_{t-1} | x_t)$, se demostró en [27] que el proceso inverso puede entrenarse usando

$$L = \min_{\theta} \mathbb{E}_{x_0 \sim \mathcal{Q}, \epsilon \sim \mathcal{N}(0, I), t \sim T(1, T)} \left\| \epsilon - \hat{\epsilon}_\theta \left(\sqrt{\alpha_t} x_0 + \sqrt{1 - \alpha_t} \epsilon, t \right) \right\|_2^2, \quad (3)$$

donde $\hat{\epsilon}_\theta(x_t, t)$ se parametriza usando una red neuronal y $\mathcal{Q}$ denota la distribución de datos. Este objetivo puede entenderse como un límite variacional ponderado sobre la verosimilitud logarítmica negativa que reduce la señal de términos a t bajo, es decir, a niveles bajos de ruido. Los modelos de difusión condicional de clase pueden realizarse condicionando el proceso inverso al conjunto deseado de etiquetas c , es decir, usando $\epsilon_\theta = \hat{\epsilon}_\theta(x_t, t, c)$.

Modelos de espacios de estados estructurados

En esencia, los modelos de espacio de estados estructurados (SSSM) se basan en una ecuación de transición en el espacio de estados de orejas lineales que vincula una secuencia de entrada unidimensional, denotada como $u(t)$, con una secuencia de salida unidimensional, denotada como $y(t)$, mediante un estado oculto $x(t)$ que es de N dimensiones,

$$\begin{aligned} x'(t) &= Ax(t) + Bu(t) \\ y(t) &= Cx(t) + Du(t), \end{aligned} \quad (4)$$

donde A , B , C y D son matrices de transición. En [31], se discute que el SSSM (Modelo de Espacio de Estado Estructurado) es un modelo prometedor para capturar dependencias a largo plazo en series temporales. Esto se consigue discretizando las relaciones de entrada y salida y representándolas como una operación de convolución. Esta operación puede calcularse eficazmente en GPUs modernas usando un núcleo personalizado. La capacidad de capturar dependencias a largo plazo está estrechamente ligada a la inicialización de la matriz de transición A de oculto a oculto, como se discute en [32]. Apilando múltiples bloques SSSM, cada uno con la normalización adecuada y capas totalmente conectadas punto a punto, de manera similar a una capa transformadora, se puede crear un Modelo de Secuencia en Espacio de Estado Estructurado (S4). El modelo S4 ha demostrado un rendimiento sobresaliente en una variedad de referencias de interacción a largo plazo y tareas de clasificación de secuencias, incluida la clasificación ECG de 12 derivaciones, como se muestra en el trabajo más reciente [21].




Fig. 1. Representación esquemática de la *arquitectura del modelo* SSSD-ECG.

Trabajo relacionado

El modelado generativo profundo para datos de series temporales es un subcampo emergente del aprendizaje automático, impulsado principalmente por el constante progreso en el desarrollo de modelos generativos, especialmente en el campo de la imagen. Aunque se han desarrollado diversas arquitecturas de algoritmos, como los autoencoders variacionales [33] y los autoencoders de derividificación apilada [34], las redes generativas adversariales (GANs) siguen siendo la tecnología dominante en el campo, especialmente con redes neuronales recurrentes (RNNs) [35–38], transformadores [39] o ecuaciones diferenciales [40] como bloques de construcción. Aunque algunas investigaciones previas han abordado la generación de series temporales condicionales [33,36,38,40,41], la mayor parte sigue limitada al entorno incondicional [35,37,39,42,43].

Durante la etapa final de la preparación del manuscrito, tomamos conocimiento de [43], cuyos autores también aplicaron un modelo de difusión para la generación sintética de ECG, aunque usando representaciones de imagen en lugar de la serie temporal directamente y para el caso restringido de la generación incondicional de ECGs de canal único. Curiosamente, este enfoque no pudo superar una línea base basada en GAN según varias métricas de calidad. También muy recientemente, Chung et al. propusieron un modelo generativo condicional para generar ECGs sintéticos a partir de informes de texto [44]. Debido a la diferente configuración de tareas, sus resultados no son directamente comparables a los nuestros, pero representan una dirección interesante para futuras investigaciones. No obstante, lo vemos como un siguiente paso importante establecer líneas base adecuadas para el caso más controlado de generación de ECG basada primero en etiquetas estructuradas.

Además de estos trabajos muy recientes, numerosos enfoques literarios han intentado abordar el problema de crear señales sintéticas de ECG, pero estos enfoques suelen estar sujetos a limitaciones significativas. En primer lugar, muchos de estos modelos solo pueden generar series temporales cortas [37–39,42], por lo que muchos de ellos se limitan a la generación de golpes individuales. En segundo lugar, con frecuencia se entrenan con pequeños conjuntos de datos de pocos pacientes [36] o con etiquetas condicionales limitadas [33,40,41]. En tercer lugar, muchos de estos enfoques requieren segmentación de pulsos ECG como paso de preprocesamiento, en lugar de trabajar directamente sobre señales continuas [33,38–40]. Además, muchos de estos enfoques presentan diferentes problemas de evaluación, como estar limitados a la generación y clasificación específicas de pacientes [41] o carecer de datos de entrenamiento y software para filtrado/extracción de características para el público general [35] (véase Fig. 1).

2.3. Modelos generativos condicionales para datos de ECG

SSSD-ECG

Volviendo a la discusión sobre la difusión probabilística en la Sección 2.2, el único componente que queda por especificar es la parametrización explícita del proceso hacia atrás, denotada por $\theta = \theta(x, t, c)$. En este sentido, hemos implementado una adaptación del modelo *SSSDS4* recientemente propuesto [45], donde *SSSD* significa difusión estructurada en el espacio de estados. El modelo se basa en la arquitectura *DiffWave* [26], que fue propuesta originalmente para la síntesis de audio mediante convoluciones dilatadas. Sin embargo, en *SSSDS4*, las convoluciones dilatadas se sustituyen por dos capas *S4* (como se describe en la Sección 2.2) para manejar mejor las dependencias a largo plazo en series temporales. Se ha demostrado que esto es eficaz para diversas imputaciones de series temporales en diferentes escenarios y tareas de previsión en [45]. *SSSD-ECG*, que se propone en este trabajo, se basa en la *arquitectura del modelo SSSDS4* pero también se desvía de ella en varios aspectos importantes. La diferencia más importante se debe a la distinta información condicional que se proporciona para las aplicaciones respectivas y a la omisión de estrategias de enmascaramiento específicas de la tarea. Mientras

SSSDS4 recibe una máscara de imputación y la señal de entrada restante como información condicional; *SSSD-ECG* está condicionado al conjunto de sentencias ECG anotadas, que en nuestro caso se codifica como un vector binario de longitud 71. Este vector se transforma en una representación continua multiplicándola con una matriz de pesos aprendible, se transforma a través de una capa completamente conectada y posteriormente se pasa como información condicional a diferentes *capas SSSD4*. Figura: [Fig. 1](#) muestra una representación esquemática de la *arquitectura del modelo SSSD-ECG*. Para más detalles sobre los componentes internos e hiperparámetros del modelo, consulte el [Apéndice C](#).

Como modificación adicional específica para cada tarea, cabe mencionar que en un ECG estándar de 12 derivaciones, solo dos de los seis derivos de las extremidades son independientes. Esto significa que cualquier conjunto de derivaciones puede reconstruirse usando cualquier par de derivaciones dadas, basándose en las relaciones definitorias IIII

$$= \text{II} - \text{I}, a\text{VL} = (\text{I} - \text{III})/2, a\text{VF} = (\text{II} + \text{III})/2, y -a\text{VR} = (\text{I} + \text{II})/2.$$

Para asegurar para que los ECGs que generamos satisfagan estas relaciones, usamos modelos generativos para sintetizar solo 8 derivaciones — las 6 derivaciones precordiales y 2 derivaciones de extremidades (I y aVF en nuestro caso). Luego reconstruimos los 4 derivados restantes muestreando de los dos derivadores (I y aVF). Este enfoque

es similar al utilizado por [35] y también se aplica a todos los modelos de referencia descritos a continuación.

Creemos que utilizar un conjunto de datos de ECG disponible públicamente para el entrenamiento es un paso fundamental hacia un progreso medible. Esto permite desvincular mejoras en la arquitectura del modelo y los calendarios de entrenamiento de las mejoras resultantes únicamente de conjuntos de datos de entrenamiento más grandes o más completos. A diferencia de limitaciones anteriores, el *modelo SSSD-ECG* genera secuencias largas de 1000 pasos de tiempo (para un ECG de 10 segundos a 100 Hz), se entrena con un amplio conjunto de datos de más de 18.000 pacientes y está condicionado a un conjunto completo de 71 declaraciones ECG. Además, genera muestras completas sin necesidad de segmentación previa ni ningún otro preprocesamiento y se basa en código público [46].

Referencias: WaveGAN* y Pulse2Pulse

Nuestra principal contribución es el *modelo SSSD-ECG*, pero también presentamos versiones condicionales de dos modelos generativos existentes para datos de ECG, a saber, WaveGAN y Pulse2Pulse [35]. Estos modelos utilizan Redes Generativas Adversariales (GANs) [47]. Hacemos que estos modelos sean condicionales a clase incorporando capas de normalización por lotes en su arquitectura y convirtiéndolas en capas de normalización por lotes condicional [48]. Esto implica hacer que los parámetros internos de desplazamiento y escalado de la capa dependan de la clase. Seguimos un enfoque similar para mapear el vector binario de etiquetas en una representación continua usando una matriz de pesos aprendida. Más detalles sobre las configuraciones del modelo y los hiperparámetros de entrenamiento se proporcionan en el [Apéndice D](#).

Lamentablemente, no tuvimos éxito en entrenar modelos generativos efectivos para nuestro caso particular utilizando implementaciones públicas, excepto WaveGAN y Pulse2Pulse como se mencionó antes. Nuestros intentos incluyeron la creación de modelos generativos para la generación de series temporales, como TTS-GAN [39] y métodos bien establecidos como TimeGAN [42], pero estos modelos probablemente se vieron desafiados por longitudes de entrada de 1000 pasos temporales. Tampoco pudimos generar muestras en 250 pasos de tiempo. Además, no tuvimos éxito en entrenar un modelo condicional de clase utilizando el enfoque cVAE_ECG [33], tal como se describe en el [Apéndice D.3](#).

2.4. Medidas de rendimiento para modelos generativos

En esta sección, nuestro objetivo es proponer medidas para cuantificar la calidad de las muestras generadas. Podemos lograr esto entrenando clasificadores en conjuntos de entrenamiento reales o sintéticos y probándolos en conjuntos de prueba reales o sintéticos. Cabe destacar que solo necesitamos entrenar un único clasificador con datos reales, al que llamaremos clasificador de referencia, que se mantiene fijo para todos los experimentos restantes. De ella, se pueden inferir tres medidas de rendimiento diferentes:

- (1) El criterio principal para evaluar la calidad de los datos sintéticos es su *capacidad para reemplazar los datos reales*. Esta evaluación consiste en probar un clasificador entrenado sobre un conjunto sintético de entrenamiento con un conjunto de pruebas real. La clasificación de varios algoritmos basados en esta medida es ampliamente considerada el estándar de oro para evaluar la calidad de los modelos de datos sintéticos, como se menciona en [49]. Sin embargo, también es valioso comparar el rendimiento absoluto del clasificador sintético con el del clasificador de referencia entrenado con datos reales.
- (2) La segunda métrica, que complementa la primera, pretende delimitar *el realismo de los datos sintéticos evaluándolos mediante un clasificador de referencia*. Esto implica utilizar el modelo de referencia, que fue entrenado con datos reales, para evaluar el rendimiento del conjunto de pruebas sintético. La disminución esperada en la performance predictiva, en comparación con la evaluación utilizando el conjunto real de pruebas, se debe a la diferencia inherente entre la distribución de los datos reales de entrenamiento y la de los datos sintéticos de prueba. Esta disminución puede servir como una segunda medida del rendimiento de los modelos generativos.

- (3) El tercer indicador de rendimiento adopta un enfoque distinto evaluando la *consistencia interna*. Evalúa qué tan bien un clasificador entrenado con datos sintéticos de entrenamiento se generaliza a datos de prueba sintéticos no vistos de la misma distribución. Para evaluar esto, un clasificador se entrena en un conjunto sintético de entrenamiento y se prueba en su correspondiente conjunto de pruebas sintéticos. Sin embargo, este criterio no hace referencia directa o indirectamente a los datos reales a través de un clasificador de referencia entrenado con datos reales, por lo que se considera menos informativo que los dos primeros criterios.

Nos gustaría llamar la atención sobre investigaciones recientes como [49], que se centran en evaluar el rendimiento de modelos generativos, específicamente en producir resultados que coincidan con un estándar predeterminado. Sin embargo, durante nuestros intentos de replicar los hallazgos, encontramos problemas de inestabilidad al entrenar la incrustación de una clase como paso necesario en [49], lo que resultó afectar significativamente a los resultados. Por ello, hemos decidido no incluir esos resultados correspondientes en nuestro artículo.

3. Experimentos y resultados


Entrenamos tres modelos generativos – *SSSD-ECG*, WaveGAN* y Pulse2Pulse – basados en los ocho pliegues de entrenamiento PTB-XL. Cada modelo estaba condicionado a las respectivas anotaciones muestrales en el conjunto de datos. Tras entrenar cada modelo, generamos una copia sintética del conjunto de datos PTB-XL de la siguiente manera: Para cada muestra en PTB-XL, generamos una nueva muestra sintética acondicionando la anotación ECG de esa muestra. Para cada uno de los tres modelos generativos, esto dio lugar a un conjunto de datos sintético de ECG que coincide con PTB-XL en tamaño y distribución de etiquetas. De este modo, obtenemos conjuntos sintéticos de entrenamiento, validación y prueba, cuyas distribuciones de etiquetas coinciden exactamente con los conjuntos correspondientes de PTB-XL. Utilizamos estos conjuntos de datos sintéticos tanto para evaluaciones cualitativas como cuantitativas de la calidad de las muestras generadas.

3.1. Evaluación cualitativa

Para realizar una evaluación cualitativa, elegimos dos condiciones habituales de ocurrencia, a saber, ECGs normales (NORM) y ECGs con hipertrofia ventricular izquierda (LVH). Para poder comparar entre muestras, realizamos segmentación a nivel de latido entre 250 muestras generadas para cada condición identificando picos R y recortando desde 300 ms antes del pico R hasta 500 ms después del pico R. Ahora, representamos la mediana de todos los tiempos junto con los correspondientes cuantiles 0,25 y 0,75 visualizados a través de una banda sombreada. Esto permite una comparación visual directa de las principales características de las muestras generadas, tanto entre diferentes modelos como en comparación con las muestras reales de PTB-XL.

[Higo. 2](#) presenta una evaluación cualitativa de muestras generadas sanas (NORM) en comparación con muestras reales. El modelo WaveGAN* produce señales con una cantidad significativa de interferencias y numerosas características ECG que difieren de las que se encuentran en señales reales, como picos R mayores y la ausencia de ondas P y T en la mayoría de los derivados debido a la inferencia de señal. El modelo Pulse2Pulse produce resultados más consistentes, con menos variabilidad entre cuantiles. Sin embargo, existen algunas características desajustadas en comparación con muestras reales, incluyendo la ausencia de un pico S en la derivación I, un pico S mayor en la derivación II y una onda T opuesta (hacia arriba) en la derivación V1. El *modelo SSSD-ECG* es el que se parece mucho a las muestras reales, con un mayor nivel de confianza ya que las bandas cuantitativas se aproximan mucho a la mediana en todas las características. Este modelo replica correctamente las ondas P y T en los derivados I y II, así como la onda T descendente en el plomo V1. Además, las características en el plomo V2, como los picos R y S y las ondas P y T, están equilibradas.


[Higo. 3](#) muestra una comparación de muestras sintéticas con hipertrofia ventricular izquierda (LVH) generada por diferentes modelos propuestos con muestras reales, basada en una evaluación cualitativa. El modelo WaveGAN* tiene mucha interferencia de señal, lo que dificulta observar ciertas



/fig. 2. De arriba a abajo, cuatro cuadrículas de derivaciones I, II, V1 y V2 respectivamente, donde para cada cuadrícula de arriba a abajo y de izquierda a derecha real, WaveGAN*, Pulse2Pulse y SSSD-ECG mediana (línea negra) y 0,25–0,75 cuantiles (área sombreada en azul) segmentan los latidos para muestras sanas (NORM).

características como las ondas P y T, aunque el pico R parece estar correctamente moldeado. En contraste, el modelo Pulse2Pulse no genera con precisión el pico R, que parece curvado hacia arriba en todos los terminales, y tampoco genera muchas otras características, como una onda T recta en V5 y una onda T descendente en V6, con un alto grado de incertidumbre. Finalmente, los gráficos SSSD-ECG son los más alineados con las muestras reales, generando un pico R correcto con ondas P relativamente cortas y ondas T balanceadas para todos los tiempos, con intervalos de confianza consistentes en todas las derivaciones.

En resumen, esta evaluación cualitativa inicial proporciona indicios de la superioridad de las muestras SSSD-ECG sobre sus competidores y es coherente con las características de las muestras reales correspondientes de PTB-XL.



/fig. 3. De arriba a abajo, cuatro cuadrículas de derivaciones I, AVL, V5 y V6 respectivamente, donde para cada cuadrícula de arriba a abajo y de izquierda a derecha real, WaveGAN*, Pulse2Pulse y SSSD-ECG mediana (línea negra) y 0,25–0,75 cuantiles (área sombreada en azul) segmentan latidos para muestras de hipertrofia ventricular izquierda (LVH).

3.2. Evaluación cuantitativa

En la Tabla 1, presentamos una comparación cuantitativa de los tres modelos generativos propuestos basada en las métricas de rendimiento introducidas en la Sección 2.4. La primera métrica muestra que SSSD-ECG supera a sus competidores con una puntuación de 0,84, frente a solo 0,60 de Pulse2Pulse y 0,58 de WaveGAN*. Una posible explicación para este resultado es que Pulse2Pulse y WaveGAN* son ambos enfoques basados en GAN, que tienden a centrarse en nodos seleccionados en lugar de cubrir toda la distribución. La segunda métrica también muestra un patrón similar, con SSSD-ECG claramente superando a Pulse2Pulse (0,71) y WaveGAN* (0,64) con una puntuación de 0,94. Según la tercera métrica, los tres enfoques alcanzan puntuaciones de 0,98 o más, lo que indica un alto grado de internismo

Tabla 1

Rendimiento de clasificación de modelos XResNet50 entrenados/evaluados con diferentes combinaciones de datos reales/sintéticos.

Modelo	AUROC	
WaveGAN*	Test real	Prueba sintetizador.
Tren real	0.9317	0.6489
Sintetizador de tren.	0.5816	0.9793
Pulse2Pulse	Test real	Prueba sintetizador.
Tren real	0.9317	0.7082
Sintetizador de tren.	0.5968	0.9950
SSSD-ECG	Test real	Prueba sintetizador.
Tren real	0.9317	0.9434
Sintetizador de tren.	0.8402	0.9822




Fig. 4. Interpolación SSSD-ECG entre una señal sana (NORM+SR) y una inferior de infarto de miocardio (IMI+SR+ABQRS) en la V1 de plomo, donde 5 señales de 100% y 0%, 75%, y 25%, 50% y 50%, 25% y 75%, y 0% y 100% de infarto de miocardio sano e inferior respectivamente.

consistencia entre los modelos. En resumen, los resultados de nuestra experiencia demuestran una clara ventaja cuantitativa del SSSD-ECG frente a sus competidores basados en GAN. Ahora reflexionaremos con más detalle sobre el rendimiento cuantitativo del SSSD-ECG y sus implicaciones:

De forma notable, por un lado, SSSD-ECG incluso logra una puntuación ligeramente mejor (0,94) evaluada a través del clasificador de referencia en comparación con la evaluación del clasificador de referencia en muestras reales. Esto es una perspectiva alentadora para auditar algoritmos de análisis ECG, ya que puede realizarse un precribado con datos sintéticos antes de evaluarlos con datos privados de alta calidad.

Por otro lado, es importante reconocer que el rendimiento SSSD-ECG durante el entrenamiento con datos sintéticos y pruebas con datos reales es notablemente inferior en comparación con el clasificador de referencia entrenado con datos reales (0,84 frente a 0,93). Es importante reiterar la dificultad de la tarea generacional que se está presentando. Este trabajo es el primer intento de construir un modelo generativo que depende de una amplia gama de 71 declaraciones de ECG. Además, no se debe subestimar el hecho de que estas 71 afirmaciones se emplean en un entorno multi-etiqueta, donde el número de combinaciones únicas de etiquetas (incluidas las condiciones concurrentes) es significativamente mayor, lo que refleja la compleja realidad de enfermedades y estados patológicos coexistentes. Algunos de los estados del ECG ya están escasamente poblados, con menos de 100 ocurrencias en todo el conjunto de datos, y esto es aún más pronunciado en el caso de combinaciones de etiquetas coexistentes. Consideramos un objetivo desafiante pero valioso para la comunidad investigadora idear métodos que puedan salvar la brecha en la situación de "entrenar en sintético, probar en real", permitiendo finalmente que los datos sintéticos se utilicen esencialmente de forma intercambiable con datos reales.




Fig. 5. Interpolación SSSD-ECG entre una señal de bloque de rama izquierda saludable (NORM+SR) y una de bloque de rama izquierda completa (CLBBB+SR) en el lead V1, donde 5 señales de 100% y 0%, 75%, y 25%, 50% y 50%, 25% y 75%, y 0% y 100% de bloque de rama izquierda sano y completo, respectivamente.

3.3. Interpolación condicional de clases

Para demostrar que el modelo SSSD-ECG ha adquirido conocimientos valiosos en el campo específico del análisis ECG, realizamos varios experimentos de interpolación en clase. A diferencia de otros modelos, nuestro modelo no se limita a usar solo vectores binarios como información condicional. En su lugar, podemos usar cualquier vector real con valores que vayan de 0 a 1. Utilizando una combinación convexa de dos vectores binarios de anotación A y B, especificados por $aa + (1 - a)b$ para $a \in [0, 1]$, podemos interpolar entre ambas condiciones. El parámetro a determina el peso dado a la condición A. La inicialización de la muestra se mantiene constante durante todo el proceso. Variando a , podemos transitar suavemente entre ambas condiciones. Para ilustrar mejor esto, dividimos las muestras generadas en función de los picos R y solo presentamos los latidos medianos extraídos de la señal. Esto facilita observar los cambios de señal a medida que pasamos de una condición a otra. Esto no solo sirve como una interesante comprobación de consistencia, sino que también abre posibilidades para modelos generativos más complejos que pueden incorporar estados de enfermedad no binarios.

Infarto de miocardio inferior

Higo. 4 muestra la interpolación entre una muestra sana y normal (NORM) y una señal de un infarto de miocardio inferior (IMI) para el plomo V1. Las etiquetas de las muestras sanas se basan en su ocurrencia en la muestra de entrenamiento y representan el NORM y el ritmo sinusal (SR). Las etiquetas para la enfermedad IMI incluyen SR, IMI y complejo QRS anormal (ABQRS). Se puede observar que las señales IMI generadas y sus interpolaciones presentan una formación temprana de onda Q, mientras que la señal normal tiene una forma más corta y descendente.

Bloque completo de rama izquierda

Higo. 5 muestra una interpolación entre una señal sana y una señal de bloque de rama izquierda completa (CLBBB) como se observa en el plomo V1. Las etiquetas asignadas a las señales se basan en la presencia de muestras de entrenamiento para señales saludables, que se etiquetan como NORM y SR, y para las señales CLBBB, que se etiquetan como SR y CLBBB. En un electrocardiograma (ECG), se observan varias características principales que son más representativas de la enfermedad de la enfermedad de la CCBB. En primer lugar, a medida que la enfermedad aumenta, el complejo QRS se ensancha, lo cual es claramente visible en las señales del 75% y 100% de CLBBB. En segundo lugar, en todas las señales, la característica RSR que caracteriza a la CLBBB se hace más grande a medida que la enfermedad avanza. Por último, también se puede observar una tendencia al alza en la onda T a medida que la enfermedad se vuelve más grave.




fig. 6. Interpolación SSSD-ECG entre una señal sana (NORM+SR) y una señal de hipertrofia ventricular izquierda (LVH+SR+VCLVH) en V5 derivado, donde 5 señales de 100% y 0%, 75%, y 25%, 50% y 50%, 25% y 75%, y 0% y 100% de hipertrofia sana y ventricular izquierda, respectivamente.

Hipertrofia ventricular izquierda

Fig. 6 muestra una interpolación entre una señal sana y una señal con hipertrofia ventricular izquierda (LVH), observada desde el plomo V5. Las etiquetas utilizadas para muestras sanas son NORM, SR, y para muestras de LVH, las etiquetas usadas son SR, LVH y criterios de voltaje (QRS) para hipertrofia ventricular izquierda (VCLVH), basadas en la incidencia de la muestra de entrenamiento. Se puede observar una característica importante del ECG de la LVH, que es el agrandamiento del pico R en uno de los electrodos del lado izquierdo (V5). A medida que avanza la enfermedad, el pico R también aumenta de tamaño, y también hay una tendencia a la baja en la onda T a medida que la enfermedad empeora.

En resumen, estos estudios de interpolación de casos, realizados en tres dominios diferentes y alineados con el conocimiento del dominio sobre las condiciones consideradas, sugieren que el SSSD-ECG ha adquirido una comprensión significativa de cómo las diferentes combinaciones de etiquetas se relacionan con características específicas de la señal.

3.4. Evaluación de expertos

Como componente final de nuestra evaluación de la calidad de la muestra, presentamos las muestras generadas a un cardiólogo clínico e intervencionista experto para su evaluación cualitativa.

Diagnóstico generativo en muestras normales

Para realizar esta tarea, proporcionamos al experto cuatro ECGs de 10 segundos y 12 derivaciones, incluyendo un ECG real y una muestra de cada uno de los modelos generativos. Estas cuatro grabaciones completas de ECG ofrecen una representación visual detallada de las muestras generadas. Luego se pidió al experto que distinguiera entre señales reales y sintéticas.

Higo. 7 representa una señal NORM real de 10 segundos que fue evaluada por el experto médico. El diagnóstico fue una muestra sintética debido a cambios en el voltaje en los electrodos I, III y AVF, y a una progresión lenta del primer vector (onda R) en los electrodos precordiales V1-V6. Higo. 8 muestra una señal WaveGAN* NORM de 10 segundos que también fue evaluada por un experto médico, y el diagnóstico fue una muestra sintética debido a la ausencia de señal sinusal, ondas P poco claras, alta interferencia, ausencia de simetría en los intervalos RR y cambios de voltaje en la misma pista. Higo. 9 representa una señal NORM Pulse2Pulse de 10 segundos que también fue evaluada por un experto médico, y el diagnóstico fue una muestra sintética debido a la variabilidad de las ondas P, la ausencia de simetría en los intervalos RR, la alta interferencia y los cambios morfológicos en la misma traza dentro del mismo electrodo. Por último, Fig. El 10 muestra una señal SSSD-ECG NORM de 10 segundos que fue diagnosticada como una muestra real por el experto médico. El diagnóstico se debió a la bien definida onda P y el intervalo RR, y aunque hubo algo de taquicardia, la señal presentaba patrones claros de isodifásico, especialmente en los derivados I y AVF.



fig. 7. Muestra real (PTB-XL) NORM.



fig. 8. Muestra sintética WaveGAN* NORM.


Prueba de Turing clínica

En esta sección, presentamos los resultados de una prueba de Turing realizada con un profesional médico mencionado anteriormente. La tarea consistió en presentar 22 pares de ECGs de 12 derivaciones (un total de 44), uno sintético (un total de 22) y el otro real (también un total de 22). Se pidió al cardiólogo que realizara dos tareas. La primera tarea fue decidir si la muestra era consistente con el conjunto proporcionado de declaraciones ECG, que se usaba para seleccionar una muestra normal correspondiente de PTB-XL o para generar la muestra sintética. La segunda tarea fue determinar si alguno de los ECG del par dado parecía sintético. En el Apéndice E, ofrecemos un desglose detallado de las distintas combinaciones involucradas, que corresponden a las combinaciones de etiquetas más frecuentes en PTB-XL, junto con resultados específicos para cada par. Sin embargo, en esta sección solo informaremos de estadísticas descriptivas simples. Las muestras originales estarán disponibles como parte del repositorio de código [46].

En la primera parte de la tarea, que consistió en evaluar muestras de diagnóstico, se evaluaron un total de 44 muestras. Entre ellos, el cardiólogo diagnosticó erróneamente 19 (43,18%) y correctamente 25 (56,81%). Específicamente, de las 22 muestras sintéticas, 7 (31,81%)



/fig. 9. Muestra sintética de Pulse2Pulse NORM.



/fig. 10. Muestra sintética SSSD-ECG NORM.

se diagnosticaron incorrectamente y 15 (68,18%) fueron diagnosticados correctamente. De manera similar, de las 22 muestras reales, el cardiólogo diagnosticó 12 (54,54%) incorrectamente y 10 (45,45%) correctamente. La mayor tasa de confirmación del 68% para las muestras sintéticas, en comparación con el 45% de las muestras reales, indica que los ECGs sintéticos son muy precisos y coinciden muy bien con sus etiquetas designadas.

En la segunda parte de la tarea, que consistió en identificar muestras sintéticas, se consideraron un total de 44 muestras. Entre ellos, el cardiólogo identificó 10 como sintéticos, lo que representa el 22,72%, y 34 como reales, lo que representa el 77,27%. De las 22 muestras sintéticas, el cardiólogo identificó 5 como sintéticas (22,72%) y 17 como reales (77,27%). De manera similar, de las 22 muestras reales, el cardiólogo identificó 5 como sintéticas (22,72%) y 17 como reales (77,27%). El hecho de que se identificaran 5 muestras como sintéticas en ambos casos confirma que es difícil para un experto médico distinguir entre muestras reales y sintéticas. Cabe destacar que esta conclusión se aplica a un conjunto diverso de 22 condiciones médicas diferentes, lo que subraya la alta calidad de las muestras sintéticas generadas.

Tabla A.2
Detalles del conjunto de datos PTB-XL.

Descripción	Valor
Tamaño del tren	17,441
Tamaño del conjunto de validación	2193
Tamaño del conjunto de prueba	2203
Longitud de muestra	1000
Característica de ejemplo	12
Sellos	71

4. Conclusión

En nuestro estudio, propusimos un enfoque novedoso llamado *SSSD-ECG* para generar datos electrocardiogramáticos (ECG) utilizando tecnologías basadas en la difusión. Condicionamos nuestro modelo a un conjunto diverso de 71 estados ECG en un entorno multi-etiqueta, lo cual es una tarea sumamente compleja. Las muestras generadas destacaron en diferentes contextos, desde la evaluación cualitativa hasta la cuantitativa hasta la interpolación condicional de etiquetas y una evaluación de expertos humanos, superando claramente a los dos competidores basados en GAN también propuestos en este trabajo. Sin embargo, observamos que las *muestras generalizadas de SSSD-ECG* no eran completamente capaces de compensar muestras reales al entrenar un clasificador sobre ellas. Creemos que cerrar esta brecha sería un logro significativo y una señal medible de progreso en el campo en un futuro próximo. Para fomentar la investigación adicional en este campo, estamos publicando el código fuente utilizado en nuestras investigaciones [46], así como los modelos entrenados y una copia sintética del conjunto de datos PTB-XL generado por *SSSD-ECG* [50].

Declaración de intereses en competencia

Los autores declaran que no tienen intereses financieros o relaciones personales en competencia que pudieran influir en el trabajo reportado en este artículo.

Agradecimientos

Los autores desean expresar su agradecimiento a Erick Dávila Zaragoza por realizar una evaluación meticulosa de las muestras generadas. El Sr. Zaragoza es cardiólogo clínico e intervencionista certificado acreditado por el Consejo Nacional de Cardiología de México como médico general de la Universidad de Guadalajara (UDG) y como cardiólogo por la Universidad Nacional Autónoma de México (UNAM).

Apéndice A. CONJUNTO DE DATOS PTB-XL

Tabla A.2 proporciona información detallada sobre el conjunto de datos PTB-XL [18–20], que es una colección de 21.837 electrocardiogramas clínicos de 12 derivaciones (ECG) tomados de 18.885 pacientes. Cada grabación de ECG dura 10 s, y todas las señales se recogieron a una frecuencia de muestreo de 100 Hz, es decir, los correspondientes 1000 pasos de tiempo por muestra. Durante los experimentos, se utilizó un conjunto de 71 etiquetas posibles en un entorno multi-etiqueta para proporcionar información condicional.

Apéndice B. Detalles de XResNet1d50

Tabla B.3 presenta los detalles de la arquitectura XResNet1d(50) propuestos en [22], junto con los hiperparámetros de entrenamiento correspondientes. La arquitectura consta de cuatro bloques con 3, 4, 6 y 3 capas, respectivamente, de convoluciones unidimensionales con una expansión de cuatro y pasos de 1. El procedimiento de entrenamiento empleó el optimizador Adam con una tasa de aprendizaje y decaimiento de peso de 1×10^{-3} para 100 épocas y un lote de 64. A diferencia de los datos generados por ECG, el clasificador se entrenó con muestras recortadas de 250 pasos de tiempo cada una. Durante la inferencia, las probabilidades medias de salida se calcularon en siete cultivos diferentes obtenidos desplazando la ventana a través de la señal usando una zancada de 125 pasos de tiempo. La media de las probabilidades de salida se utilizó entonces como predicción para toda la muestra.

Tabla B.3

Hiperparámetros XResNet1d50.

Hiperparámetro	Valor
Bloque de capas	4
Capas en cada bloque	[3,4,6,3]
Expansión	4
Zancada	1
Optimizador	Adán
Tasa de aprendizaje	1×10^{-3}
Decaimiento del peso	1×10^{-3}
Tamaño del lote	64
Épocas	100

Tabla C.4

Hiperparámetros SSSD-ECG.

Hiperparámetro	Valor
Capas residuales	36
Canales residuales	256
Saltar canales	256
Incrustación de difusión dim. 1	128
Incrustación de difusión dim. 2	512
Incrustación de difusión dim. 3	512
Calendario	Lineal
Pasos de difusión T	200
$B0$	0.0001
$B1$	0.02
Optimizador	Adán
Función de pérdida	MSE
Tasa de aprendizaje	2×10^{-4}
Tamaño del lote	4

Tabla D.5

Hiperparámetros WaveGAN*.

Hiperparámetro	Valor
Tamaño del modelo del generador	50
Bloques deconvolucionales generadores	5
Dimensiones latentes del generador	1000
Tamaño del modelo del discriminador	50
Bloques convolucionales discriminadores	6
Función de pérdida del optimizador	Adam MSE
Tasa de aprendizaje	0.0001
Épocas de entrenamiento	3000
Tamaño del lote	32

Tabla D.6

Pulse2Hiperparámetros Pulse.

Hiperparámetro	Valor
Tamaño del modelo del generador	50
Bloques deconvolucionales generadores	5
Tamaño del modelo del discriminador	50
Bloques convolucionales discriminadores	6
Optimizador	Adán
Función de pérdida	MSE
Tasa de aprendizaje	0.0001
Épocas de entrenamiento	3000
Tamaño del lote	32

Apéndice C. Detalles del SSSD-ECG

Tabla C.4 proporciona información detallada sobre la arquitectura de la SSSD-ECG modelo de difusión, que consiste en una red de 36 capas residuales apiladas con 256 canales residuales y de salto. Para una discusión comprensiva de la arquitectura del modelo, remitimos al lector a [45]. El SSSD-ECG El modelo utiliza una función de activación swishing en el segundo y tercer nivel y tiene una incrustación de difusión de tres niveles en dimensiones 128, 256 y 256. Para calcular la difusión inicial de S4, estructuramos una capa convolucional tras la incrustación de difusión para duplicar la dimensión residual del canal de entrada. Luego empleamos una segunda capa S4 que aumentaba la información condicional y su inclusión en la entrada. La salida se enrutaba a través de una no linealidad con tanh con compuertas, y se utilizaba una capa convolucional para proyectar los canales residuales de vuelta a la dimensionalidad del canal. En cuanto a los hiperparámetros, usamos 200 pasos de tiempo en un calendario lineal para la configuración de difusión, con un valor beta que va de 0,0001 a 0,02. Empleamos a Adam como optimizador con una tasa de aprendizaje de 2×10^{-4} . Para aprender las dependencias temporales de las series en ambas direcciones para el modelo S4, utilizamos una única capa bidireccional S4. Basándose en investigaciones previas [31] utilizamos normalización de capas y una dimensionalidad interna de estado de $N = 64$.

Apéndice D. Detalles de referencia

D.1. Detalles de Wavegan*

Tabla D.5 muestra la arquitectura y los hiperparámetros de entrenamiento utilizados en la implementación de WaveGAN*. El generador toma un vector unidimensional de 1000 puntos de datos muestreados de una distribución uniforme y lo pasa por cinco bloques de deconvolución para generar una señal de salida compuesta por 1000 pasos de tiempo y 8 derivaciones de ECG. Cada bloque de deconvolución está compuesto por cuatro capas: una capa de upsampling, una capa de relleno, una capa de convolución 1D y una función de activación de ReLU, en ese orden. Los modelos de discriminador y generador tienen un tamaño de 50 cada uno. En el entorno condicional, incorporamos una normalización por lotes condicional en cada convolución del generador. Esta normalización por lotes toma un lote de etiquetas para condicionar, que se pasa por una capa de incrustación con una dimensión de incrustación el doble que la de las dimensiones del canal de salida, y luego se añade a la salida de la convolución.

D.2. Detalles de Pulse2Pulse

La Tabla D.6 presenta la arquitectura y los hiperparámetros de entrenamiento utilizados en la implementación de Pulse2Pulse. Pulse2Pulse es una arquitectura similar a una red U, pero que se diferencia en su uso de capas convolucionales unidimensionales para generar señales de electrocardiograma (ECG). El generador recibe una entrada que consta de 1000 pasos de tiempo y 8 canales muestreados de una distribución uniforme. Esta entrada pasa por cinco bloques de muestreo descendente y cinco bloques de muestreo ascendente, donde la técnica de muestreo ascendente utilizada es similar a la de WaveGAN*. El proceso de reducción de muestreo implica una convolución unidimensional y una función de activación de Leaky ReLU. Para la configuración condicional, añadimos una normalización por lotes temporal a cada convolución del generador. Esta normalización por lotes incluye un lote de etiquetas para condicionar la salida, que luego pasa por una incrustación de palabras con un tamaño de dimensión de incrustación el doble de la dimensión del canal de salida. Finalmente, el resultado de la incrustación de palabras se añade a la salida de la convolución.

D.3. Otras líneas base

En este último apéndice, nos gustaría comentar sobre varios modelos de referencia que hemos probado para nuestro caso de uso. En concreto, no pudimos entrenar modelos generativos funcionales usando TTS-GAN, TimeGAN y cVAE_ECG.

Los autores presentaron un modelo GAN llamado TTS-GAN [39], como un modelo generativo incondicional para datos de series temporales. Realizaron varios experimentos para probar el modelo, incluido uno en el que generaron datos electrocardiográficos (ECG). Implementamos TTS-GAN con diferentes profundidades de capas para el generador y el discriminador, incluyendo capas 4, 6, 12 y 24. Además, usamos diferentes dimensiones latentes para el generador, como 128, 256 y 1000. Como nuestra secuencia era de 1000, usamos principalmente dos configuraciones. La primera configuración tenía un tamaño de parche de 200 y una dimensión de incrustación de 5, mientras que la segunda configuración tenía valores de 100 y 10, respectivamente. El proceso de entrenamiento consistió en 200 épocas con un tamaño de lote de 4 y una tasa de aprendizaje de 0,0001 y 0,0003 para el generador y el discriminador, respectivamente.

De manera similar, TimeGAN [42] es un modelo GAN bien conocido utilizado para generar datos de series temporales incondicionales. Sus creadores realizaron varios experimentos para probar su eficacia, aunque en su mayoría en señales de corta duración. Intentamos entrenar el modelo TimeGAN usando los hiperparámetros predeterminados recomendados por los autores, incluyendo un GRU de 3 capas

Tabla E.7
Evaluación del diagnóstico en la prueba de Turing.

Set	Sellos	A(P)	B(P)
1	NORM, SR	Cierto	Falso
2	NDT, SR	Falso	Cierto
3	ABQRS, IMI, SR	Cierto	Falso
4	NORM, SARRH	Cierto	Cierto
5	LAFB SR	Falso	Cierto
6	NORM SBRAD	Cierto	Cierto
7	RTIMO	Cierto	Cierto
8	CLBBB, SR	Cierto	Falso
9	LVH, SR, VCLVH	Falso	Falso
10	NORM	Cierto	Falso
11	IRBBB, SR	Cierto	Falso
12	ABQRS, NORM, SR	Cierto	Cierto
13	IRBBB, NORM, SR	Cierto	Falso
14	NORM, STACH	Falso	Cierto
15	IMI, SR	Falso	Cierto
16	ISC_, LVH, SR	Cierto	Cierto
17	ABQRS, ASMI, SR	Cierto	Falso
18	NST_, SR	Falso	Cierto
19	NDT, NT_, SR	Cierto	Falso
20	ABQRS, ASMI, IMI, SR	Falso	Cierto
21	LVH, SR	Falso	Falso
22	AFIB, NST_	Cierto	Falso

Tabla E.8
Evaluación sintética de la prueba de Turing.

Set	Sellos	A(T)	B(T)	A(P)	B(P)
1	NORM, SR	Falso	Cierto	Falso	Cierto
2	NDT, SR	Falso	Cierto	Falso	Falso
3	ABQRS, IMI, SR	Cierto	Falso	Falso	Cierto
4	NORM, SARRH	Cierto	Falso	Falso	Falso
5	LAFB SR	Falso	Cierto	Cierto	Falso
6	NORM SBRAD	Cierto	Falso	Falso	Cierto
7	RTIMO	Falso	Cierto	Falso	Cierto
8	CLBBB, SR	Falso	Cierto	Falso	Cierto
9	LVH, SR, VCLVH	Falso	Cierto	Falso	Cierto
10	NORM	Cierto	Falso	Falso	Falso
11	IRBBB, SR	Cierto	Falso	Falso	Cierto
12	ABQRS, NORM, SR	Cierto	Falso	Falso	Falso
13	IRBBB, NORM, SR	Falso	Cierto	Falso	Falso
14	NORM, STACH	Falso	Cierto	Falso	Falso
15	IMI, SR	Cierto	Falso	Falso	Falso
16	ISC_, LVH, SR	Falso	Cierto	Falso	Falso
17	ABQRS, ASMI, SR	Cierto	Falso	Falso	Falso
18	NST_, SR	Cierto	Falso	Falso	Falso
19	NDT, NT_, SR	Cierto	Falso	Falso	Falso
20	ABQRS, ASMI, IMI, SR	Falso	Cierto	Falso	Cierto
21	LVH, SR	Falso	Cierto	Falso	Falso
22	AFIB, NST_	Cierto	Falso	Falso	Cierto

módulo con 24 dimensiones ocultas, un tamaño de lote de 4 y 2000 iteraciones de entrenamiento. Sin embargo, no pudimos observar ninguna muestra generada de forma significativa.

Los autocodificadores variacionales (VAE) son un marco popular para el modelado generativo. cVAE_ECG [33] es un modelo generativo condicional diseñado específicamente para datos de ECG. Sin embargo, se diferencia de nuestro enfoque ap- en que requiere segmentación de beats como paso de preprocesamiento, en lugar de generar señales continuas. Además, el espacio de conjunto de etiquetas de su conjunto de datos implementado es relativamente pequeño. En nuestro trabajo, utilizamos una tasa de aprendizaje de 0,001, un tamaño de lote de 4 y varias dimensiones convolucionales de filtros, incluyendo 3, 5, 8 y 10, así como núcleos convolucionales con dimensiones de longitud 10, 50, 100, 500 y 1000. También experimentamos con espacios latentes de 10, 20, 50, 100 y 1000, con una dimensionalidad condicional de 71 dadas las etiquetas del conjunto de datos. Sin embargo, a pesar de estos esfuerzos, no pudimos producir reconstrucciones razonables utilizando la arquitectura del modelo dada.

Apéndice E. Prueba de Turing clínica: Desglose detallado de los resultados

Tabla E.7 presenta información sobre la fase inicial del test de Turing, que consistió en evaluar predicciones diagnósticas. Las predicciones

para la muestra A y la muestra B se representaban por A(P) y B(P), respectivamente. El objetivo era determinar si el conjunto dado de etiquetas coincidía con precisión con la muestra representada. Verdadero se usaba para indicar diagnósticos correctos, mientras que falso indicaba diagnósticos incorrectos.

La Tabla E.8 presenta detalles sobre la evaluación sintética que se realizó como segunda parte de la prueba de Turing. En la tabla, A(T), B(T), A(P) y B(P) denotan la etiqueta verdadera para la muestra A o B, así como las etiquetas predichas para la muestra A o B, respectivamente. El valor "verdadero" indica una muestra sintética, mientras que "falso" indica una muestra real.